



PROYECTO DE CLASIFICACIÓN HOSPITALARIA DE EGRESO POR MEJORÍA

CASO: GENTERA

Luis Alberto Rueda Tapia

ORIGEN DEL REQUISITO:


- Se busca poder hacer la clasificación de aquellos pacientes que egresaron por mejoría tomando en cuenta las variables existentes de

DIAS_ESTANCIA	EDAD	GENERO	PESO	ALTURA	IMC	MES	ENTIDAD	INDIGENA	MOTIVO_EGRESO	CODIGO_ENFERMEDAD	CODIGO_ENFERMEDAD_DESC	Tipo de Problema
1	23	2	63	147	29.154519	2	29	2	1	0809	Cólera debido a Vibrio cholerae 01, biotipo cholerae	Ciertas enfermedades infecciosas y parasitarias


OBSERVACIONES EN LOS DATOS

- Se tiene un total de 19,894 datos cada uno con un ID distinto por lo que se asegura la independencia entre datos,


Distribución por sexo



Preguntando si es indigena



Edades del dataset



OBSERVACIONES EN LOS DATOS

- Se tiene un total de 19,894 datos cada uno con un ID distinto por lo que se asegura la independencia entre datos,



OBSERVACIONES EN LOS DATOS

- Se implemento una nueva columna llamada nivel de gravedad en función del tipo de problema (Esta columna es documentada con información de la OMS Global Health Estimates (2021) / INEGI Defunciones Registradas (2023) / IHME GBD)

	A	B	C	D	E
1	CODIGO_ENI	CODIGO_ENFERMEDAD_DESC	Tipo de Problema	Nivel de gravedad	
2	A000	Cólera debido a Vibrio cholerae 01, biotipo cholerae	Ciertas enfermedades infecciosas y parasitarias	4	
3	A001	Cólera debido a Vibrio cholerae 01, biotipo el Tor	Ciertas enfermedades infecciosas y parasitarias	4	
4	A009	Cólera, no especificado	Ciertas enfermedades infecciosas y parasitarias	4	
5	A010	Fiebre tifoidea	Ciertas enfermedades infecciosas y parasitarias	4	
6	A011	Fiebre paratifoidea A	Ciertas enfermedades infecciosas y parasitarias	4	
7	A012	Fiebre paratifoidea B	Ciertas enfermedades infecciosas y parasitarias	4	
8	A013	Fiebre paratifoidea C	Ciertas enfermedades infecciosas y parasitarias	4	
9	A014	Fiebre paratifoidea, no especificada	Ciertas enfermedades infecciosas y parasitarias	4	
10	A020	Enteritis debida a Salmonella	Ciertas enfermedades infecciosas y parasitarias	4	
11	A021	Sepsis debida a Salmonella	Ciertas enfermedades infecciosas y parasitarias	4	
12	A022	Infecciones localizadas debidas a Salmonella	Ciertas enfermedades infecciosas y parasitarias	4	
13	A028	Otras infecciones especificadas como debidas a Salmonella	Ciertas enfermedades infecciosas y parasitarias	4	
14	A029	Infección debida a Salmonella, no especificada	Ciertas enfermedades infecciosas y parasitarias	4	
15	A030	Shigelosis debida a Shigella dysenteriae	Ciertas enfermedades infecciosas y parasitarias	4	
16	A031	Shigelosis debida a Shigella flexneri	Ciertas enfermedades infecciosas y parasitarias	4	
17	A032	Shigelosis debida a Shigella boydii	Ciertas enfermedades infecciosas y parasitarias	4	
18	A033	Shigelosis debida a Shigella sonnei	Ciertas enfermedades infecciosas y parasitarias	4	
19	A038	Otras shigelosis	Ciertas enfermedades infecciosas y parasitarias	4	


NUMERO DE DATOS NULOS

...

	tipo	nulos	porcentaje_nulos	valores_unicos
ALTURA	float64	2894	9.68	171
IMC	float64	2894	9.68	3455
ID	int64	0	0.00	29894
CODIGO_ENFERMEDAD	object	0	0.00	2289
ES_INDIGENA	int64	0	0.00	3
NIVEL_DE_GRAVEDAD	float64	0	0.00	5
TIPO_DE_PROBLEMA_MEDICO	str	0	0.00	20
CODIGO_ENFERMEDAD_DESC	str	0	0.00	2288
GRUPO_ETARIO	category	0	0.00	5
EDAD_CUADRADO	int64	0	0.00	106
INDIGENA	int64	0	0.00	3
MOTIVO_EGRESO	int64	0	0.00	8
DIAS_ESTANCIA	int64	0	0.00	107
ENTIDAD	int64	0	0.00	32
MES	int64	0	0.00	12
PESO	int64	0	0.00	163
GENERO	int64	0	0.00	2
EDAD	int64	0	0.00	106
EGRESO_MEJORIA	int8	0	0.00	2

TAMAÑO DEL MUESTREO Y CORRELACIONES

	frecuencia	
EGRESO_MEJORIA	1	26793
	0	3101



MODELO BASE+ COMBINACIONES

```
columns_modelo = [  
    "DIAS_ESTANCIA", "EDAD", "EDAD_CUADRADO", "GRUPO_ETARIO", "GENERO",  
    "NIVEL_DE_GRAVEDAD", "IMC", "ES_INDIGENA", "ENTIDAD", "MES",  
]
```

Experimento	Base (7)	EDAD	CÓD. ENF.	TIPO PROB.	EDAD²	GRP. ETARIO	Total
base_8_variables	✓	✓	—	—	—	—	8
base_mas_codigo_enfermedad	✓	✓	✓	—	—	—	9
base_mas_tipo_problema	✓	✓	—	✓	—	—	9
base_mas_codigo_y_tipo	✓	✓	✓	✓	—	—	10
edad_cuadrado	✓	—	—	—	✓	—	8
grupo_etario	✓	—	—	—	—	✓	8
edad_y_edad_cuadrado	✓	✓	—	—	✓	—	9
edad_y_grupo_etario	✓	✓	—	—	—	✓	9
edad_cuadrado_y_grupo_etario	✓	—	—	—	✓	✓	9
todas_las_variables_de_edad	✓	✓	—	—	✓	✓	10

RESULTADOS DE LOS MODELOS

Escenario	Modelo	CV ROC-AUC	CV F1	Test ROC-AUC	Test F1	Prec.	Recall	Acc.
base_8_variables	Random Forest	0.758	0.837	0.766	0.832	0.946	0.743	0.731
edad_cuadrado	Random Forest	0.758	0.837	0.766	0.832	0.946	0.743	0.731
edad_y_edad_cuadrado	Random Forest	0.754	0.835	0.760	0.830	0.944	0.741	0.729
base_mas_tipo_problema	Random Forest	0.745	0.842	0.754	0.850	0.941	0.775	0.755
grupo_etario	Random Forest	0.745	0.832	0.748	0.826	0.943	0.735	0.722
edad_cuadrado_y_grupo_etario	Random Forest	0.743	0.837	0.743	0.830	0.939	0.744	0.728
edad_y_grupo_etario	Random Forest	0.743	0.837	0.743	0.830	0.939	0.744	0.727
todas_las_variables_de_edad	Random Forest	0.739	0.840	0.739	0.837	0.939	0.756	0.737
base_mas_codigo_y_tipo	Random Forest	0.677	0.847	0.690	0.850	0.924	0.787	0.751
base_mas_codigo_enfermedad	Random Forest	0.683	0.818	0.689	0.814	0.930	0.724	0.704
base_8_variables	Random Forest	0.758	0.837	0.766	0.832	0.946	0.743	0.731
base_mas_tipo_problema	Random Forest	0.745	0.842	0.754	0.850	0.941	0.775	0.755
base_mas_codigo_y_tipo	Regresión Log.	0.656	0.817	0.673	0.822	0.930	0.737	0.714
base_8_variables	Regresión Log.	0.606	0.775	0.602	0.779	0.915	0.679	0.656
base_mas_codigo_y_tipo	SVM Lineal	0.641	0.945	0.658	0.945	0.896	1.000*	0.896
base_8_variables	SVM Lineal	0.606	0.945	0.602	0.945	0.896	1.000*	0.896
base_8_variables	Baseline	0.500	0.945	0.500	0.945	0.896	1.000	0.896

RESULTADOS DE LOS MODELOS


Mejor escenario: base_8_variables

Mejor modelo: random_forest

Variables utilizadas: ['DIAS_ESTANCIA', 'GENERO', 'NIVEL_DE_

	precision	recall	f1-score	support
0	0.222	0.634	0.329	620
1	0.946	0.743	0.832	5359
accuracy			0.731	5979
macro avg	0.584	0.688	0.580	5979
weighted avg	0.871	0.731	0.780	5979

Matriz de confusión - base_8_variables / random_forest



OPTIMIZACIÓN DE HIPERPARAMETROS

Tabla Comparativa de Modelos Calibrados



Modelo	Estado	Validación Cruzada (cv)			Métricas en Test				
		CV ROC-AUC	Train ROC	Brecha	Test ROC-AUC	Test F1	Precisión	Recall	Accuracy
Random Forest	Calibrado	0.7575	0.8300	0.0726	0.7732	0.8204	0.9495	0.7222	0.7165
Regresión Logística	Calibrado	0.6065	0.6105	0.0040	0.6020	0.7794	0.9152	0.6787	0.6556
SVM Lineal	Calibrado	0.6063	0.6103	0.0040	0.6017	0.9453	0.8963	1.0000*	0.8963

*Nota: SVM Lineal presenta un Recall de 1.0000 debido a la clasificación sistemática hacia la clase mayoritaria en este umbral de calibración.



Configuración e Hiperparámetros Óptimos

Modelo	Tipo	Criterio Generalización	Mejores Hiperparámetros (Grid/RandomSearch)
Random Forest	Calibrado	0.7394	{ 'max_depth': 14, 'max_features': 'sqrt', 'min_samples_leaf': 40, 'n_estimators': 500 }
Regresión Logística	Calibrado	0.6055	{ 'C': 1.0 }
SVM Lineal	Calibrado	0.6054	{ 'estimator__C': 2.0 }

RESULTADOS DEL MODELO FINAL



RESULTADOS DEL MODELO FINAL



CALIBRACIÓN FINAL

Métricas de Rendimiento

Métrica	Resultado
ROC-AUC Promedio (CV)	0.7575
ROC-AUC en Prueba	0.7693
F1 Score	0.8202
Precisión	0.9479
Recall	0.7229
Accuracy	0.7160
Brier Score	0.1873
Average Precision (PR-AUC)	0.9633

Configuración de Hiperparámetros

Hiperparámetro	Valor Configurado
n_estimators	500
max_depth	14
min_samples_leaf	40
max_features	"sqrt"
class_weight	"balanced"
criterion	"gini"
bootstrap	True